




Podstawowe informacje

1. Za drugi projekt można otrzymać maksymalnie 10 punktów.
2. Ocena przyznawana jest na podstawie realizacji zadania opisanego niżej.
3. Termin wykonania: **14 czerwca (niedziela)**. Do tego czasu należy wysłać prowadzącym laboratoria mailem opisane niżej pliki, jak również umieścić swoje predykcje na platformie *Kaggle* (szczegóły niżej). Każde rozpoczęte 6 godzin opóźnienia wiąże się z obniżeniem punktacji o 2 punkty.
4. Przesłane prowadzącemu pliki powinny mieć prefiks „NazwiskoImie_Indeks_”, na przykład KowalskiJan_123456_raport.html.

Zadanie

Jesteście zatrudnieni w firmie zarządzającej rowerami miejskimi. Zostaliście przydzieleni do projektu IPN (*Inteligentne Planowanie Napraw*), w ramach którego Waszym obowiązkiem będzie możliwie dokładne przewidywanie liczby rowerów wypożyczanych w najbliższych dniach.

Wasz przełożony zlecił Wam skonstruowanie prototypu modelu predykcyjnego na podstawie części dostępnych danych, zawartych w pliku `bike_train.csv`. Obejmują one informacje z roku 2022: dla każdego dnia z tego zakresu (zmienna `date`) zarejestrowano liczbę wypożyczonych rowerów (zmienna `count`) oraz następujące parametry meteorologiczne:

- `temp`: temperatura [°C]
- `atemp`: temperatura odczuwalna [°C]
- `hum`: wilgotność [%]
- `wind`: prędkość wiatru [km/h]
- `wcond`: warunki pogodowe
 - 1: pogodnie / lekkie zachmurzenie
 - 2: pochmurnie / mgła
 - 3: lekki opad
 - 4: duży opad

Macie przesłać przełożonemu krótki raport w formie pliku `html` (wygenerowanego przez kod `RMarkdown`), który zawiera podstawową analizę danych połączoną z konstrukcją modelu predykcyjnego. Szczegółowe wymagania dotyczące zawartości raportu są następujące:

1. (1 punkt) W raporcie powinny znaleźć się podstawowe informacje o danych:

- (a) Informacja, czy brakuje jakichś wartości w danych – a jeśli tak, w jaki sposób sobie z tym brakiem dalej poradzono.
- (b) Wykres temperatury i liczby wypożyczonych rowerów w zależności od dnia (oba wykresy na jednej grafice).
- (c) Macierz korelacji w formie „mapy ciepła” (z naniesionymi wartościami liczbowymi) między zmiennymi ilościowymi związanymi z warunkami pogodowymi.

Ponadto

- (d) Do danych należy dołączyć zmienną binarną **weekend**, przyjmującą wartość 1 jeśli dany dzień wypadł w weekend oraz 0 w przeciwnym przypadku. Zmienna ta powinna zostać wykorzystana w dalszej predykcji.

2. (1 punkt) Należy przeprowadzić analizę składowych głównych na ilościowych zmiennych meteorologicznych. W raporcie powinna się znaleźć informacja o najmniejszej liczbie składowych głównych odpowiadających za co najmniej 90% sumarycznej wariancji tych danych.

Dalsza część raportu wiąże się z predykcją liczby wypożyczonych rowerów (**count**) na podstawie dostępnych w danych pozostałych zmiennych. Optymalizowaną funkcją straty ma być błąd średniokwadratowy.

3. (2 punkty) W tej części projektu należy wytrenować model lasów losowych.

- (a) Spośród wielu hiperparametrów charakteryzujących model lasów losowych wybierz trzy różne. Zdefiniuj trójwymiarową siatkę przeszukiwanych kombinacji hiperparametrów i za pomocą 5-krotnej walidacji krzyżowej wybierz ich optymalne (w kontekście wykonywanej predykcji) wartości. W ramach przeszukiwania należy sprawdzić co najmniej 100 konfiguracji parametrów.
- (b) Narysuj wykres kropkowy – każda kropka odpowiada pewnej konfiguracji hiperparametrów, a jej współrzędne X/Y to uzyskany dla tej konfiguracji błąd treningowy/walidacyjny (należy uśrednić wynik względem wszystkich podzbiorów testowych wyróżnionych w walidacji krzyżowej). Wyróżnij na tym wykresie konfigurację o najmniejszym błędzie walidacyjnym.

4. (2 punkty) Wykonaj na danych *regresję grzbietową*.

- (a) Zdefiniuj siatkę dla hiperparametru ściągnięcia λ , obejmującą 10 jego wartości. Wykonaj 5-krotną walidację krzyżową, **wykorzystując te same foldy, co w poprzednim punkcie**.
- (b) Narysuj wykres, w którym na osi X odłożone są wartości hiperparametru λ , zaś na osi Y – odpowiadające tym hiperparametrom wartości błędu średniokwadratowego w poszczególnych foldach (tzn. każdej wartości λ odpowiada 10 punktów). Na wykresie, innym kolorem, należy również podać błąd walidacji krzyżowej dla każdego wyboru λ .
- (c) Podaj λ przy którym błąd walidacyjny jest najmniejszy. Porównaj ów błąd walidacyjny z błędem dla lasów losowych z poprzedniego podpunktu.

5. (1 punkt) Zrób podsumowanie tabelaryczne wyników, jakie otrzymywały metody w walidacji krzyżowej w obu rozważanych powyżej modelach (tzn. lasy losowe oraz regresja grzbietowa). Porównanie to jest powodem, dla którego zależy nam na zastosowaniu tych samych podziałów walidacji krzyżowej. Do porównania dołącz trzeci model, referencyjny, również poddany walidacji krzyżowej, tzn. model, który dowolnym wartościom zmiennych objaśniających w foldzie testowym przypisuje średnią arytmetyczną zmiennej objaśnianej policzoną w foldach treningowych.

6. Wykorzystaj wytrenowany wyżej model (lub inny – szczegóły niżej) do predykcji na danych testowych, umieszczonych na platformie Kaggle [*link zostanie umieszczony w niniejszej specyfikacji, jak również na Moodle, najpóźniej 31 maja*]. W wiadomości do prowadzącego labę, zawierającej opisany wyżej raport, będzie należało zamieścić swoją nazwę użytkownika na platformie Kaggle (pod jaką będzie się występowało na *leaderboardzie*), jak również plik z predykcjami, wysłanymi na Kaggle.

Punktacja za tę część zależy od tego, czy wyniki załączonej predykcji będą miały na zbiorze testowym mniejszy błąd, niż dwa modele wytrenowane przez prowadzących – A i B – z których drugi będzie trenowany z dużo mniejszą starannością niż pierwszy.

- (a) (*1 punkt*) Predykcja lepsza niż model B wytrenowany przez prowadzących (będzie wyróżniony na Kaggle).
- (b) (*2 punkty*) Predykcja lepsza niż model A wytrenowany przez prowadzących (będzie wyróżniony na Kaggle).

Predykcja na Kaggle może być otrzymana przy pomocy innego modelu, niż dwa opisane wyżej. W takim wypadku należy do rozwiązania dołączyć skrypt `R/RMarkdown` trenujący wybrany model na dostarczonych danych treningowych (bez etapu wyboru optymalnych hiperparametrów danego modelu) i obliczający przewidywane przez ów model wartości dla zbioru testowego.

Pozycja predykcji na leaderboardze nie będzie miała wpływu na punktację za to zadanie. Z drugiej strony, osiągnięcie wysokiego miejsca będzie odnotowane przez prowadzących zajęcia, co – w granicznych sytuacjach – może (nie musi) mieć korzystny wpływ na ocenę z przedmiotu.

Uwagi na koniec

- Należy zadbać o to, by wykorzystywane w analizie zmienne były miały stosowny do zadania format (numeryczny/jakościowy/data...)
- W dostarczonym raporcie kod generujący odpowiednie fragmenty powinien być ukryty, z możliwością „odkrycia”. Efekt ten można uzyskać, wstawiając do nagłówka YAML kodu następujący fragment

```
output:  
  html_document:  
    code_folding: hide
```

- Pytania dotyczące projektu warto zadawać na utworzonym na Moodle forum – dzięki temu do odpowiedzi będą mieli od razu dostęp wszyscy uczestnicy kursu.